

THU GIẢM SỐ CHIỀU

PRINCIPAL COMPONENT ANALYSIS - PCA

Lê Thành Sách

✉ Itsach@hcmut.edu.vn

Khoa Khoa học & Kỹ thuật Máy tính
Trường Đại học Bách Khoa - ĐHQG Tp.HCM

Tp.HCM. Ngày 14 tháng 10 năm 2019

Dimensionality
Reduction

Mục lục

Giới thiệu về PCA

PCA qua API

Kiến thức toán
liên quan

Cơ sở lý luận của
PCA

Cực đại hóa
variance

Thu giảm số chiều

Singular Value
Decomposition

Ứng dụng của
PCA

Tổng kết và Câu
hỏi

Mục lục

① Giới thiệu về PCA

- Đầu vào
- Mục tiêu

② PCA qua API

③ Kiến thức toán liên quan

④ Cơ sở lý luận của PCA

⑤ Cực đại hóa variance

- Nguyên tắc
- Khi $k=1$
- Khi $k=M$
- Khi $k=M+1$

⑥ Thu giảm số chiều

⑦ Singular Value Decomposition

⑧ Ứng dụng của PCA

⑨ Tổng kết và Câu hỏi



Dimensionality
Reduction

1

Mục lục

Giới thiệu về PCA

PCA qua API

Kiến thức toán
liên quan

Cơ sở lý luận của
PCA

Cực đại hóa
variance

Thu giảm số chiều

Singular Value
Decomposition

Ứng dụng của
PCA

Tổng kết và Câu
hỏi

60



Dimensionality
Reduction

Mục lục

2

Giới thiệu về PCA

Dầu vào

Mục tiêu

PCA qua API

Kiến thức toán
liên quan

Cơ sở lý luận của
PCA

Cực đại hóa
variance

Thu giảm số chiều

Singular Value
Decomposition

Ứng dụng của
PCA

60

Tổng kết và Câu

Giới thiệu về PCA

Giới thiệu bài toán

Dữ liệu đầu vào

1 Dữ liệu đầu vào:

$$\mathbf{X} = \begin{bmatrix} x_{1,1} & x_{1,2} & \cdots & x_{1,D} \\ x_{2,1} & x_{2,2} & \cdots & x_{2,D} \\ x_{3,1} & x_{3,2} & \cdots & x_{3,D} \\ \vdots & \vdots & \ddots & \vdots \\ x_{N,1} & x_{N,2} & \cdots & x_{N,D} \end{bmatrix}$$

- $\mathbf{X}$ có kích thước $N \times D$, thường D rất lớn
- Không gian đặc trưng có D chiều, phần nhiều các chiều có tương quan nhau (phụ thuộc hàm với nhau)

Giới thiệu bài toán



Dimensionality Reduction

Mục lục

Giới thiệu về PCA

4

Dầu vào

Mục tiêu

PCA qua API

Kiến thức toán liên quan

Cơ sở lý luận của PCA

Cực đại hóa variance

Thu giảm số chiều

Singular Value Decomposition

Ứng dụng của PCA

60

Tổng kết và Câu

Trở ngại khi với dữ liệu nhiều chiều, Curse of Dimensionality

① Độ phức tạp tính toán tăng lên, như:


- tính ma trận K_{Gram} , ma trận kernel, ma trận hiệp phương sai, ...;
- tính khoảng cách giữa các điểm dữ liệu;
- số neuron lớp ẩn tăng lên (mạng Nơron nhân tạo).

② Cần mô hình phức tạp hơn (nhiều tham số hơn) $\Rightarrow$ cần số điểm dữ liệu lớn hơn, nếu không tình trạng **overfitting** rất dễ xảy ra.

Giới thiệu bài toán

Mục tiêu

- 1 Giảm số chiều dữ liệu từ D xuống M và $M \ll D$
- 2 Các đặc trưng sau khi thu giảm không còn tương quan nhau (uncorrelated).



Hình 1.1: Dữ liệu từ D chiều còn M chiều mà vẫn mô tả tốt dữ liệu

Giới thiệu bài toán



Dimensionality Reduction

Mục lục

Giới thiệu về PCA

Dầu vào

6

Mục tiêu

PCA qua API

Kiến thức toán liên quan

Cơ sở lý luận của PCA

Cực đại hóa variance


Thu giảm số chiều

Singular Value Decomposition

Ứng dụng của PCA


60

Tổng kết và Câu



Hình 1.2: Sau khi chiếu dữ liệu gốc lên các vectơ e_1 và e_2 , phương sai (variance) theo chiều e_2 là khá nhỏ (**như nhiều**) $\Rightarrow$ có thể bỏ đi; nghĩa là, chỉ giữ lại tọa độ của điểm dữ liệu trên chiều e_1

Giới thiệu bài toán



Hình 1.3: Biểu đồ của các **variance** theo các chiều tối ưu: dữ liệu có sự biến thiên rất nhỏ theo phần lớn các chiều $\Rightarrow$ có thể thu giảm chiều. Lưu ý: **variance** được tính trên tập dữ liệu của các số viết tay, kích thước $28 \times 28 = 784$ chiều. Nguồn: “PRnML” C.M. Bishop, pp.566



Dimensionality Reduction

Mục lục

Giới thiệu về PCA

Dầu vào

7

Mục tiêu

PCA qua API

Kiến thức toán liên quan

Cơ sở lý luận của PCA

Cực đại hóa variance

Thu giảm số chiều

Singular Value Decomposition

Ứng dụng của PCA

60

Tổng kết và Câu

Giới thiệu bài toán



Dimensionality
Reduction

Mục lục

Giới thiệu về PCA

Dầu vào

8

Mục tiêu

PCA qua API

Kiến thức toán
liên quan

Cơ sở lý luận của
PCA

Cực đại hóa
variance

Thu giảm số chiều


Singular Value
Decomposition

Ứng dụng của
PCA


60

Tổng kết và Câu


Original




$M = 1$




$M = 10$



$M = 50$



$M = 250$



Hình 1.4: Ảnh của các chữ số khôi phục được từ M chiều được giữ lại. Tập dữ liệu: như Hình 1.3. Nguồn: “PRnML” C.M. Bishop, pp.567



Dimensionality Reduction

Mục lục

Giới thiệu về PCA

9

PCA qua API

Kiến thức toán liên quan

Cơ sở lý luận của PCA

Cực đại hóa variance

Thu giảm số chiều

Singular Value Decomposition

Ứng dụng của PCA

Tổng kết và Câu hỏi

PCA qua API

PCA qua API



Example (PCA trong Scikit-learn)

```
1 import numpy as np
2 from sklearn.decomposition import PCA
3 X = np.array([
4     [-1, -1], [-2, -1],
5     [-3, -2], [1, 1],
6     [2, 1], [3, 2]])
7 pca = PCA(n_components=2)
8 pca.fit(X)
9 print(pca.explained_variance_ratio_)
10 print(pca.singular_values_)
```

Xem thêm: <https://scikit-learn.org/stable/modules/generated/sklearn.decomposition.PCA.html>

Dimensionality
Reduction

Mục lục

Giới thiệu về PCA

10 PCA qua API

Kiến thức toán
liên quan

Cơ sở lý luận của
PCA

Cực đại hóa
variance

Thu giảm số chiều


Singular Value
Decomposition

Ứng dụng của
PCA

Tổng kết và Câu
hỏi

Kiến thức toán liên quan

Tài liệu tham khảo



Hình 3.1: Introduction to Linear Algebra (Gilbert Strang)

The Matrix Cookbook

Kaare Brandt Petersen
Michael Syskind Pedersen

VERSION: JANUARY 5, 2005

What is this? These pages are a collection of facts (identities, approximations, inequalities, relations, ...) about matrices and matters relating to them. It is collected in this form for the convenience of anyone who wants a quick desktop reference.

Disclaimer: The identities, approximations and relations presented here were obviously not invented but collected, borrowed and copied from a large amount of sources. These sources include similar but shorter notes found on the internet and appendices in books - see the references for a full list.

Errors: Very likely there are errors, typos, and mistakes for which we apologize and would be grateful to receive corrections at kbp@imm.dtu.dk.

Its ongoing: The project of keeping a large repository of relations involving matrices is naturally ongoing and the version will be apparent from the date in the header.

Suggestions: Your suggestion for additional content or elaboration of some topics is most welcome at kbp@imm.dtu.dk.

Acknowledgements: We would like to thank the following for discussions, proofreading, extensive corrections and suggestions: Esben Hoegh-Rasmussen and Vasilé Sima.

Keywords: Matrix algebra, matrix relations, matrix identities, derivative of determinant, derivative of inverse matrix, differentiate a matrix.

Hình 3.2: The Matrix Cookbook



Dimensionality
Reduction

Mục lục

Giới thiệu về PCA

PCA qua API

12 Kiến thức toán
liên quan

Cơ sở lý luận của
PCA

Cực đại hóa
variance

Thu giảm số chiều

Singular Value
Decomposition

Ứng dụng của
PCA

Tổng kết và Câu
hỏi

Kiến thức toán liên quan

1 Hình chiếu của vectơ $\mathbf{x}$ lên vectơ $\mathbf{u}$

$$\ell_{\mathbf{xou}} = \frac{\mathbf{u} \cdot \mathbf{x}}{\|\mathbf{u}\|} = \frac{\mathbf{u}^T \mathbf{x}}{\|\mathbf{u}\|} \quad (3.1)$$

- $\ell_{\mathbf{xou}}$: có thể âm hay dương tùy vào góc tạo bởi hai vectơ $\mathbf{x}$ và $\mathbf{u}$.

2 Dạng bậc 2:

$$\begin{aligned} \mathbf{u} &= [u_1, u_2, \dots, u_N]^T \\ \mathbf{v} &= [v_1, v_2, \dots, v_M]^T \\ \mathbf{A} &= [a_{ij}]_{N \times M} \\ \mathbf{u}^T \mathbf{A} \mathbf{v} &= \sum_{i=1}^N \sum_{j=1}^M \underbrace{a_{ij}}_{\text{số vô hướng}} \underbrace{u_i^T v_j}_{\text{số vô hướng}} \end{aligned} \quad (3.2)$$

Dimensionality Reduction

Mục lục

Giới thiệu về PCA

PCA qua API

13 Kiến thức toán liên quan

Cơ sở lý luận của PCA

Cực đại hóa variance

Thu giảm số chiều

Singular Value Decomposition

Ứng dụng của PCA

Tổng kết và Câu hỏi

Kiến thức toán liên quan

③ Chuyển vị tích ma trận:

$$(\mathbf{ABC})^T = \mathbf{C}^T \mathbf{B}^T \mathbf{A}^T \quad (3.3)$$

④ Đạo hàm:

$$\frac{\partial \mathbf{u}^T \mathbf{u}}{\partial \mathbf{u}} = 2\mathbf{u} \quad \text{Jacobian: } 2\mathbf{u}^T \quad (3.4)$$

$$\begin{aligned} \frac{\partial \mathbf{u}^T \mathbf{A} \mathbf{u}}{\partial \mathbf{u}} &= (\mathbf{A} + \mathbf{A}^T) \mathbf{u} \\ &= 2\mathbf{A} \mathbf{u} \quad \text{nếu } \mathbf{A} \text{ đối xứng} \end{aligned} \quad (3.5)$$



Dimensionality
Reduction

Mục lục

Giới thiệu về PCA

PCA qua API

14

Kiến thức toán
liên quan

Cơ sở lý luận của
PCA

Cực đại hóa
variance

Thu giảm số chiều

Singular Value
Decomposition

Ứng dụng của
PCA

Tổng kết và Câu
hỏi

60

Kiến thức toán liên quan

5 Phương trình **eigenvector** và **eigenvalue**:

$$\mathbf{A}u = \lambda u \quad (3.6)$$

Ma trận **A** biến đổi vectơ **u**, kết quả của biến đổi chỉ là co hay giãn vectơ **u** một lượng λ .

- **A**: ma trận vuông
- **u**: eigenvector
- λ : eigenvalue



Dimensionality
Reduction

Mục lục

Giới thiệu về PCA

PCA qua API

15 Kiến thức toán
liên quan

Cơ sở lý luận của
PCA

Cực đại hóa
variance

Thu giảm số chiều

Singular Value
Decomposition

Ứng dụng của
PCA

Tổng kết và Câu
hỏi

Kiến thức toán liên quan

⑥ Cách tìm **eigenvector** và **eigenvalue**:

$$\mathbf{A}u = \lambda u$$

$$\Leftrightarrow \mathbf{A}u - \lambda \mathbf{I}u = 0$$

$$\Leftrightarrow (\mathbf{A} - \lambda \mathbf{I})u = 0 \quad (3.7)$$

$$\Rightarrow \det(\mathbf{A} - \lambda \mathbf{I}) = 0 \quad (3.8)$$

P.T (3.8): characteristic equation

- ① Giải P.T (3.8) để tìm λ (có tối đa N eigenvalue, N là kích thước ma trận $\mathbf{A}$)¹
- ② Thế lần lượt các λ vào P.T (3.7) và giải tìm các eigenvector.

¹Xem ví dụ: <https://www.scss.tcd.ie/~dahyotr/CS1BA1/SolutionEigen.pdf>



Dimensionality
Reduction

Mục lục

Giới thiệu về PCA

PCA qua API

16 Kiến thức toán
liên quan

Cơ sở lý luận của
PCA

Cực đại hóa
variance

Thu giảm số chiều

Singular Value
Decomposition

Ứng dụng của
PCA

Tổng kết và Câu
hỏi

Kiến thức toán liên quan



Dimensionality
Reduction

Mục lục

Giới thiệu về PCA

PCA qua API

17 Kiến thức toán
liên quan

Cơ sở lý luận của
PCA

Cực đại hóa
variance

Thu giảm số chiều

Singular Value
Decomposition

Ứng dụng của
PCA

Tổng kết và Câu
hỏi

⑥ Tính chất của **eigenvector** và **eigenvalue**:

Ma trận **A** là đối xứng chứa các số thực¹

- **A** có N eigenvector trực giao và N eigenvalue là số thực không âm: $\lambda_i, i = 1, 2, \dots, N$.
- Hạng của ma trận **A** là số lượng eigenvalue lớn hơn 0
- Định thức của **A** là tích của các eigenvalue
- **trace** của **A** là tổng của các eigenvalue
- Khi hạng của **A** là N , ma trận $\mathbf{A}^{-1}$ có N eigenvalue là $\frac{1}{\lambda_i}, i = 1, 2, \dots, N$

¹Xem thêm:



Cơ sở lý luận của PCA

Dimensionality
Reduction

Mục lục

Giới thiệu về PCA

PCA qua API

Kiến thức toán
liên quan

18

Cơ sở lý luận của
PCA

Cực đại hóa
variance

Thu giảm số chiều

Singular Value
Decomposition

Ứng dụng của
PCA

Tổng kết và Câu
hỏi

60

Cơ sở lý luận của PCA



Hai quan điểm về PCA, xem Hình 4.1

Dữ liệu đầu vào: N điểm thuộc không gian D -chiều. PCA tìm ra không gian con M -chiều ($M < D$) sao cho:

- khi chiếu dữ liệu gốc lên không gian này thì thu được dữ liệu mới có variance là lớn nhất¹.
- **Hoặc**, khi chiếu dữ liệu gốc lên không gian này thì thu được dữ liệu mới có sai số (khoảng cách) đến dữ liệu gốc là nhỏ nhất.

¹so với những không gian con M -chiều khác

Dimensionality
Reduction

Mục lục

Giới thiệu về PCA

PCA qua API

Kiến thức toán
liên quan

19

Cơ sở lý luận của
PCA

Cực đại hóa
variance

Thu giảm số chiều

Singular Value
Decomposition

Ứng dụng của
PCA

Tổng kết và Câu
hỏi

60

Cơ sở lý luận của PCA



Dimensionality Reduction

Mục lục

Giới thiệu về PCA

PCA qua API

Kiến thức toán liên quan

20

Cơ sở lý luận của PCA



Cực đại hóa variance

Thu giảm số chiều

Singular Value Decomposition

Ứng dụng của PCA

Tổng kết và Câu hỏi



Hai cách tiếp cận cho cùng kết quả

Hình 4.1: Hai cách tiếp cận của PCA



Cực đại hóa variance

Dimensionality
Reduction

Mục lục

Giới thiệu về PCA

PCA qua API

Kiến thức toán
liên quan

Cơ sở lý luận của
PCA

21 Cực đại hóa
variance

Nguyên tắc

Khi $k=1$

Khi $k=M$

Khi $k=M+1$

Thu giảm số chiều

Singular Value
Decomposition

60 Ứng dụng của
PCA

Cực đại hóa variance



Nguyên tắc

- ❶ Tìm ra hướng (vectơ) đầu tiên cho ra variance cực đại
 - ❶ Tính variance của dữ liệu khi chiếu lên vectơ cần tìm
 - ❷ Cực đại hóa variance $\Rightarrow$ chuyển về bài toán tối ưu có ràng buộc
 - ❸ Sử dụng Lagrangian để tìm nghiệm
- ❷ Giả sử đã tìm ra M vectơ đầu tiên
 - ❶ Các vectơ đều có **chiều dài là 1** và **từng đôi một trực giao nhau**
- ❸ Tìm hướng thứ $M + 1$

Dimensionality Reduction

Mục lục

Giới thiệu về PCA

PCA qua API

Kiến thức toán liên quan

Cơ sở lý luận của PCA

Cực đại hóa variance

22 Nguyên tắc

Khi $k=1$

Khi $k=M$

Khi $k=M+1$

Thu giảm số chiều

Singular Value Decomposition

Ứng dụng của PCA

Cực đại hóa variance

Khi $k=1$

Biến cần tìm: $\mathbf{u}$

- $\mathbf{u}$: là một véctơ, là hướng cần tìm trong không gian đặc trưng.
- Mục tiêu: tìm $\mathbf{u}$ để khi chiếu các điểm dữ liệu lên phương này thu được **variance** lớn nhất
 - Cần ép buộc $\|\mathbf{u}\| = 1$ để độ dài của một véctơ khi chiếu lên hướng này có ý nghĩa.



Dimensionality
Reduction

Mục lục

Giới thiệu về PCA

PCA qua API

Kiến thức toán
liên quan

Cơ sở lý luận của
PCA

Cực đại hóa
variance

Nguyên tắc

23 Khi $k=1$

Khi $k=M$

Khi $k=M+1$

Thu giảm số chiều

Singular Value
Decomposition

Ứng dụng của
PCA

60

Cực đại hóa variance

Khi $k=1$

Điểm trung tâm và dịch dữ liệu về trung tâm

- Điểm trung tâm của dữ liệu là:

$$\mu = \frac{1}{N} \sum_{n=1}^N \mathbf{x}_n \quad (5.1)$$

- $\mathbf{z}_n$: điểm tương ứng của $\mathbf{x}_n$ sau khi dịch $\mathbf{x}_n$ về tâm μ , xem Hình 5.1

$$\mathbf{z}_n = \mathbf{x}_n - \mu; \quad \forall n = 1, 2, \dots, N \quad (5.2)$$



Dimensionality
Reduction

Mục lục

Giới thiệu về PCA

PCA qua API

Kiến thức toán
liên quan

Cơ sở lý luận của
PCA

Cực đại hóa
variance

Nguyên tắc

24 Khi $k=1$

Khi $k=M$

Khi $k=M+1$

Thu giảm số chiều

Singular Value
Decomposition

60 Ứng dụng của
PCA

Cực đại hóa variance

Khi $k=1$

variance của dữ liệu sau khi chiếu lên u

$$\begin{aligned}\sigma^2 &= \frac{1}{N} \sum_{n=1}^N (u^T z_n)^2 &= \frac{1}{N} \sum_{n=1}^N (u^T z_n)(u^T z_n) \\&= \frac{1}{N} \sum_{n=1}^N (u^T z_n)(z_n^T u) &= \frac{1}{N} \sum_{n=1}^N u^T [z_n z_n^T] u \\&= \frac{1}{N} \sum_{n=1}^N u^T [(x_n - \mu)(x_n - \mu)^T] u &= u^T S u\end{aligned}\tag{5.3}$$



Dimensionality
Reduction

Mục lục

Giới thiệu về PCA

PCA qua API

Kiến thức toán
liên quan

Cơ sở lý luận của
PCA

Cực đại hóa
variance

Nguyên tắc

25 Khi $k=1$

Khi $k=M$

Khi $k=M+1$

Thu giảm số chiều

Singular Value
Decomposition

60 Ứng dụng của
PCA

Cực đại hóa variance

Khi $k=1$

covariance matrix: ma trận hiệp phương sai

$$\begin{aligned}\mathbf{S} &= \frac{1}{N} \sum_{n=1}^N (\mathbf{x}_n - \boldsymbol{\mu})(\mathbf{x}_n - \boldsymbol{\mu})^T \\ &= \mathbf{Z}^T \mathbf{Z} \\ &= (\mathbf{X} - \boldsymbol{\mu})^T (\mathbf{X} - \boldsymbol{\mu})\end{aligned}\tag{5.4}$$

- **S**: Ma trận vuông, đối xứng, có kích thước $D \times D$
- **S**: bán định dương



Dimensionality
Reduction

Mục lục

Giới thiệu về PCA

PCA qua API

Kiến thức toán
liên quan

Cơ sở lý luận của
PCA

Cực đại hóa
variance

Nguyên tắc

26

Khi $k=1$

Khi $k=M$

Khi $k=M+1$

Thu giảm số chiều


Singular Value
Decomposition

60

Ứng dụng của
PCA

Cực đại hóa variance

Khi $k=1$



Hình 5.1: Độ dài của vectơ z_n khi chiếu lên u

Cực đại hóa variance

Khi $k=1$

- Hướng cần tìm (gọi là $\mathbf{u}_1$) là nghiệm của bài toán tối ưu sau:

Bài toán tối ưu

$$\begin{aligned} \mathbf{u}_1 &= \underset{\mathbf{u}}{\operatorname{argmin}} \mathbf{u}^T \mathbf{S} \mathbf{u} \\ \text{s.t: } \mathbf{u}^T \mathbf{u} &= 1 \end{aligned} \quad (5.5)$$

Đặc điểm

- $\mathbf{S}$: bán định dương $\Rightarrow$ hàm mục tiêu lồi
- Giải: sử dụng phương pháp nhân tử Lagrange

Dimensionality Reduction

Mục lục

Giới thiệu về PCA

PCA qua API

Kiến thức toán liên quan

Cơ sở lý luận của PCA

Cực đại hóa variance

Nguyên tắc

28

Khi $k=1$

Khi $k=M$

Khi $k=M+1$

Thu giảm số chiều

Singular Value Decomposition

60

Ứng dụng của PCA

Cực đại hóa variance

Khi $k=1$

Lagrangian

$$\mathcal{L}(\mathbf{u}, \lambda) = \mathbf{u}^T \mathbf{S} \mathbf{u} - \lambda(\mathbf{u}^T \mathbf{u} - 1) \quad (5.6)$$

$$\begin{aligned} \frac{\partial \mathcal{L}(\mathbf{u}, \lambda)}{\partial \mathbf{u}} = 0 &\Leftrightarrow \mathbf{S} \mathbf{u} - \lambda \mathbf{u} = 0 \\ &\Leftrightarrow \mathbf{S} \mathbf{u} = \lambda \mathbf{u} \end{aligned} \quad (5.7)$$



Dimensionality Reduction

Mục lục

Giới thiệu về PCA

PCA qua API

Kiến thức toán liên quan

Cơ sở lý luận của PCA

Cực đại hóa variance

Nguyên tắc

29 Khi $k=1$

Khi $k=M$

Khi $k=M+1$

Thu giảm số chiều

Singular Value Decomposition

60 Ứng dụng của PCA

Cực đại hóa variance

Khi $k=1$

Bài toán tìm eigenvectors và eigenvalues

$$Su_1 = \lambda_1 u_1 \quad (5.8)$$

Nghiệm:

- u_1 : eigenvector, hướng cho ra variance lớn nhất
- λ_1 : eigenvalue, giá trị variance

Tính chất của eigenvectors và eigenvalues

$$\lambda_1 = u_1^T Su_1 \quad (5.9)$$

Lưu ý: λ_1 : eigenvalue; chính là **variance** của dữ liệu khi chiếu lên vectơ u_1

Dimensionality
Reduction

Mục lục

Giới thiệu về PCA

PCA qua API

Kiến thức toán
liên quan

Cơ sở lý luận của
PCA

Cực đại hóa
variance

Nguyên tắc

30

Khi $k=1$

Khi $k=M$

Khi $k=M+1$

Thu giảm số chiều

Singular Value
Decomposition

60

Ứng dụng của
PCA

Cực đại hóa variance

Khi $k=M$



Dimensionality
Reduction

Bài toán tối ưu

$$\mathbf{u}_M = \underset{\mathbf{u}}{\operatorname{argmin}} \mathbf{u}^T \mathbf{S} \mathbf{u}$$

$$\text{s.t: } \mathbf{u}^T \mathbf{u} = 1$$

$$\mathbf{u}^T \mathbf{u}_k = 0$$

$$\forall k = 1, 2, \dots, (M-1) \quad (5.10)$$

Mục tiêu

- Tìm hướng thứ M ($\mathbf{u}_M$), trực giao với **tất cả** các hướng $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_{M-1}$, để khi chiếu dữ liệu lên hướng này thì thu được variance lớn nhất (vẫn nhỏ hơn hoặc bằng $\lambda_1, \lambda_2, \dots, \lambda_{M-1}$)
- Độ lớn của $\mathbf{u}_M$ là 1

- Giả thiết: đã tìm được cặp $\mathbf{u}_k$ và λ_k cho $k = 2, \dots, M$ từ bài toán tối ưu ở trên.

Mục lục

Giới thiệu về PCA

PCA qua API

Kiến thức toán liên quan

Cơ sở lý luận của PCA

Cực đại hóa variance

Nguyên tắc

Khi $k=1$

31

Khi $k=M$

Khi $k=M+1$

Thu giảm số chiều

Singular Value Decomposition

Ứng dụng của PCA

60

Cực đại hóa variance

Khi $k=M+1$



Dimensionality
Reduction

Bài toán tối ưu

Mục tiêu

$$\begin{aligned} \mathbf{u}_{M+1} &= \underset{\mathbf{u}}{\operatorname{argmin}} \mathbf{u}^T \mathbf{S} \mathbf{u} \\ \text{s.t:} \quad & \mathbf{u}^T \mathbf{u} = 1 \\ & \mathbf{u}^T \mathbf{u}_k = 0 \\ & \forall k = 1, 2, \dots, M \end{aligned} \quad (5.11)$$

- Tìm hướng thứ $M+1$ ($\mathbf{u}_{M+1}$), trực giao với **tất cả** các hướng $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_M$, để khi chiếu dữ liệu lên hướng này thì thu được variance lớn nhất (vẫn nhỏ hơn hoặc bằng $\lambda_1, \lambda_2, \dots, \lambda_M$)
- Độ lớn của $\mathbf{u}_{M+1}$ là 1

Mục lục

Giới thiệu về PCA

PCA qua API

Kiến thức toán liên quan

Cơ sở lý luận của PCA

Cực đại hóa variance

Nguyên tắc

Khi $k=1$

Khi $k=M$

32

Khi $k=M+1$

Thu giảm số chiều

Singular Value Decomposition

Ứng dụng của PCA

- Cần suy ra bài toán tối ưu ở đây có nghiệm.

60

Cực đại hóa variance

Khi $k=M+1$

- Lagrangian:

$$\mathcal{L}(\mathbf{u}, \lambda, \boldsymbol{\mu}) = \mathbf{u}^T \mathbf{S} \mathbf{u} - \lambda (\mathbf{u}^T \mathbf{u} - 1) - \sum_{k=1}^M \mu_k (\mathbf{u}^T \mathbf{u}_k)$$

- Đạo hàm của Lagrangian theo biến gốc:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{u}} = 2\mathbf{S} \mathbf{u} - 2\lambda \mathbf{u} - \sum_{k=1}^M \mu_k \mathbf{u}_k$$



Dimensionality
Reduction

Mục lục

Giới thiệu về PCA

PCA qua API

Kiến thức toán
liên quan

Cơ sở lý luận của
PCA

Cực đại hóa
variance

Nguyên tắc

Khi $k=1$

Khi $k=M$

33

Khi $k=M+1$

Thu giảm số chiều

Singular Value
Decomposition

60

Ứng dụng của
PCA

Cực đại hóa variance

Khi $k=M+1$

- Điểm làm Lagrangian cực tiểu là nghiệm của:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{u}} = 0$$
$$\Leftrightarrow 2\mathbf{S}\mathbf{u} - 2\lambda\mathbf{u} - \sum_{k=1}^M \mu_k \mathbf{u}_k = 0 \quad (5.12)$$



Dimensionality
Reduction

Mục lục

Giới thiệu về PCA

PCA qua API

Kiến thức toán
liên quan

Cơ sở lý luận của
PCA

Cực đại hóa
variance

Nguyên tắc

Khi $k=1$

Khi $k=M$

34

Khi $k=M+1$

Thu giảm số chiều

Singular Value
Decomposition

60

Ứng dụng của
PCA

Cực đại hóa variance

Khi $k=M+1$

Lưu ý: Trong P.T (5.12), $\mu_k = 0, \forall k = 1, \dots, M$, vì:

- 1 $\mathbf{u}_k^T \mathbf{S} \mathbf{u} = \mathbf{u}^T \mathbf{S} \mathbf{u}_k = \mathbf{u}^T \lambda_k \mathbf{u}_k = \lambda_k \mathbf{u}^T \mathbf{u}_k = 0, k = 1, \dots, M$
- 2 Nhân hai vế (bên trái) của P.T (5.12) với $\mathbf{u}_k$ và áp dụng tính chất: các vectơ $\mathbf{u}_k$ và $\mathbf{u}$ từng đôi một trực giao.

Do đó, hướng cho ra variance cực đại là:

$$\begin{aligned} 2\mathbf{S}\mathbf{u} - 2\lambda\mathbf{u} &= 0 \\ \Leftrightarrow \mathbf{S}\mathbf{u} &= \lambda\mathbf{u} \end{aligned} \quad (5.13)$$

Dimensionality Reduction

Mục lục

Giới thiệu về PCA

PCA qua API

Kiến thức toán liên quan

Cơ sở lý luận của PCA

Cực đại hóa variance

Nguyên tắc

Khi $k=1$

Khi $k=M$

35

Khi $k=M+1$

Thu giảm số chiều

Singular Value Decomposition

60

Ứng dụng của PCA

Cực đại hóa variance

Khi $k=M+1$

Nghiệm

- $\mathbf{u}_{M+1}$: eigenvector thứ $(M + 1)$
- λ_{M+1} : eigenvalue tương ứng của $\mathbf{u}_{M+1}$

$$\mathbf{S}\mathbf{u}_{M+1} = \lambda_{M+1}\mathbf{u}_{M+1}$$

$$\lambda_{M+1} = \mathbf{u}_{M+1}^T \mathbf{S}\mathbf{u}_{M+1}$$



Dimensionality Reduction

Mục lục

Giới thiệu về PCA

PCA qua API

Kiến thức toán liên quan

Cơ sở lý luận của PCA

Cực đại hóa variance

Nguyên tắc

Khi $k=1$

Khi $k=M$

36 Khi $k=M+1$

Thu giảm số chiều

Singular Value Decomposition

Ứng dụng của PCA

Cực đại hóa variance

Tổng kết

- Khi $\mathbf{S}$ là một ma trận hiệp phương sai của đám điểm trong $\mathbf{X}$, thì $\mathbf{u}^T \mathbf{S} \mathbf{u}$ variance của dữ mới thu được khi chiếu các điểm trong $\mathbf{X}$ lên phương của $\mathbf{u}$.
- “Cực đại hóa variance” dẫn đến giải phương trình

$$\mathbf{S} \mathbf{u} = \lambda \mathbf{u} \quad (5.14)$$

- P.T (5.14) có D^1 cặp $\langle \mathbf{u}_k, \lambda_k \rangle$ thỏa mãn, với $k = 1, 2, \dots, D$; chúng được gọi là các cặp **eigenvector** và **eigenvalue**

¹ D là số chiều của vectơ đặc trưng trong $\mathbf{X}$



Dimensionality Reduction

Mục lục

Giới thiệu về PCA

PCA qua API

Kiến thức toán liên quan

Cơ sở lý luận của PCA

Cực đại hóa variance

Nguyên tắc

Khi $k=1$

Khi $k=M$

37 Khi $k=M+1$

Thu giảm số chiều

Singular Value Decomposition

Ứng dụng của PCA

60

Cực đại hóa variance

Tổng kết

- D eigenvectors có đôi một trực giao nhau và có độ dài là đơn vị $\Rightarrow$ hình thành **cơ sở trực giao chuẩn** (orthonormal basis)
- Gọi $\mathbf{U}$ và $\mathbf{D}$ là các ma trận cho sau đây; các vectơ $\mathbf{u}_k$ được sắp xếp theo thứ tự **giảm dần** của các eigenvalue tương ứng.

$$\mathbf{U} = \begin{bmatrix} \uparrow & \uparrow & & \uparrow \\ \mathbf{u}_1 & \mathbf{u}_2 & \cdots & \mathbf{u}_D \\ \downarrow & \downarrow & & \downarrow \end{bmatrix} \quad \mathbf{D} = \begin{bmatrix} \lambda_1 & & & \\ & \lambda_2 & & \\ & & \ddots & \\ & & & \lambda_D \end{bmatrix}$$



Dimensionality Reduction

Mục lục

Giới thiệu về PCA

PCA qua API

Kiến thức toán liên quan

Cơ sở lý luận của PCA

Cực đại hóa variance

Nguyên tắc

Khi $k=1$

Khi $k=M$

38

Khi $k=M+1$

Thu giảm số chiều

Singular Value Decomposition

60

Ứng dụng của PCA

Cực đại hóa variance

Tổng kết



Dimensionality
Reduction

Mục lục

Giới thiệu về PCA

PCA qua API

Kiến thức toán
liên quan

Cơ sở lý luận của
PCA

Cực đại hóa
variance

Nguyên tắc

Khi $k=1$

Khi $k=M$

39

Khi $k=M+1$

Thu giảm số chiều

Singular Value
Decomposition

60

Ứng dụng của
PCA

Tính chất của ma trận U và D

- 1 Chuyển vị và nghịch đảo: $U^T = U^{-1}$ (Vì, $UU^T = I$)
- 2 $SU = UD$ (xem slide sau)
- 3 $S = UDU^{-1} = UDU^T = \sum_{k=1}^D \lambda_k u_k u_k^T$ (eigenvalue decomposition)
- 4 $U^{-1}SU = U^T SU = D$ (diagonalization for S)

Cực đại hóa variance



Tính chất của ma trận U và D

Dimensionality Reduction

Mục lục

Giới thiệu về PCA

PCA qua API

Kiến thức toán liên quan

Cơ sở lý luận của PCA

Cực đại hóa variance

Nguyên tắc

Khi $k=1$

Khi $k=M$

40 Khi $k=M+1$

Thu giảm số chiều

Singular Value Decomposition

Ứng dụng của PCA

60

$$\begin{aligned} \mathbf{S}\mathbf{U} &= \mathbf{S} \begin{bmatrix} \uparrow & \uparrow & & \uparrow \\ \mathbf{u}_1 & \mathbf{u}_2 & \cdots & \mathbf{u}_D \\ \downarrow & \downarrow & & \downarrow \end{bmatrix} = \begin{bmatrix} \uparrow & \uparrow & & \uparrow \\ \mathbf{S}\mathbf{u}_1 & \mathbf{S}\mathbf{u}_2 & \cdots & \mathbf{S}\mathbf{u}_D \\ \downarrow & \downarrow & & \downarrow \end{bmatrix} \\ &= \begin{bmatrix} \uparrow & \uparrow & & \uparrow \\ \lambda_1 \mathbf{u}_1 & \lambda_2 \mathbf{u}_2 & \cdots & \lambda_D \mathbf{u}_D \\ \downarrow & \downarrow & & \downarrow \end{bmatrix} \\ &= \begin{bmatrix} \uparrow & \uparrow & & \uparrow \\ \mathbf{u}_1 & \mathbf{u}_2 & \cdots & \mathbf{u}_D \\ \downarrow & \downarrow & & \downarrow \end{bmatrix} \begin{bmatrix} \lambda_1 & & & \\ & \lambda_2 & & \\ & & \ddots & \\ & & & \lambda_D \end{bmatrix} \\ &= \mathbf{U}\mathbf{D} \end{aligned}$$

Cực đại hóa variance

Tổng kết

- Gọi $\mathbf{X}$ và $\mathbf{X}_U$ là biểu diễn của các điểm dữ liệu trong cơ sở gốc và cơ sở trực giao chuẩn cho bởi $\mathbf{U}$.

$$\mathbf{X} = \begin{bmatrix} \leftarrow & \mathbf{x}_1^T & \rightarrow \\ \leftarrow & \mathbf{x}_2^T & \rightarrow \\ & \vdots & \\ \leftarrow & \mathbf{x}_N^T & \rightarrow \end{bmatrix} \quad \mathbf{X}_U = \begin{bmatrix} \leftarrow & \mathbf{x}_{u,1}^T & \rightarrow \\ \leftarrow & \mathbf{x}_{u,2}^T & \rightarrow \\ & \vdots & \\ \leftarrow & \mathbf{x}_{u,N}^T & \rightarrow \end{bmatrix}$$



Dimensionality Reduction

Mục lục

Giới thiệu về PCA

PCA qua API

Kiến thức toán liên quan

Cơ sở lý luận của PCA

Cực đại hóa variance

Nguyên tắc

Khi $k=1$

Khi $k=M$

41 Khi $k=M+1$

Thu giảm số chiều

Singular Value Decomposition

Ứng dụng của PCA

Cực đại hóa variance

Tổng kết

- Biểu diễn của $\mathbf{X}$ trong cơ sở trực giao chuẩn $\mathbf{U}$, xem Hình 5.3 ¹:

$$\mathbf{X}_U = (\mathbf{X} - \mu^T) \mathbf{U} = \mathbf{Z} \mathbf{U} \quad (5.15)$$

- Biểu diễn của $\mathbf{X}_U$ trong hệ tọa độ gốc, xem Hình 5.4:

$$\begin{aligned} \mathbf{X} &= \mu^T + \mathbf{Z} \\ &= \mu^T + \mathbf{X}_U \mathbf{U}^{-1} \\ &= \mu^T + \mathbf{X}_U \mathbf{U}^T \end{aligned} \quad (5.16)$$

¹Lưu ý: cần phải **broadcast** để μ^T có chiều của $\mathbf{X}$



Dimensionality Reduction

Mục lục

Giới thiệu về PCA

PCA qua API

Kiến thức toán liên quan

Cơ sở lý luận của PCA

Cực đại hóa variance

Nguyên tắc

Khi $k=1$

Khi $k=M$

42 Khi $k=M+1$


Thu giảm số chiều

Singular Value Decomposition

Ứng dụng của PCA

Cực đại hóa variance

Tổng kết



Hình 5.2: Nhân hai ma trận

Dimensionality Reduction

Mục lục

Giới thiệu về PCA

PCA qua API

Kiến thức toán liên quan

Cơ sở lý luận của PCA

Cực đại hóa variance

Nguyên tắc

Khi $k=1$

Khi $k=M$

43 Khi $k=M+1$


Thu giảm số chiều

Singular Value Decomposition

Ứng dụng của PCA

Cực đại hóa variance


Tổng kết



Hình 5.3: Biểu diễn dữ liệu $\mathbf{X}$ trong không gian các **eigenvector**

Cực đại hóa variance

Tổng kết



Hình 5.4: Chuyển các điểm trong không gian các **eigenvector** về không gian gốc



Thu giảm số chiều

Dimensionality Reduction

Mục lục

Giới thiệu về PCA

PCA qua API

Kiến thức toán liên quan

Cơ sở lý luận của PCA

Cực đại hóa variance

46 Thu giảm số chiều

Singular Value Decomposition

Ứng dụng của PCA

Tổng kết và Câu hỏi

Thu giảm số chiều



Các ma trận

- 1 $\mathbf{X}$: ma trận dữ liệu gốc
- 2 $\hat{\mathbf{U}}$: ma trận chứa M eigenvector đầu tiên (tương ứng M eigenvalue lớn nhất)
- 3 $\hat{\mathbf{U}}^T$: ma trận chuyển vị của $\hat{\mathbf{U}}$, dùng để phục hồi dữ liệu gốc
- 4 $\hat{\mathbf{X}}$: ma trận dữ liệu biểu diễn trong không gian con cho bởi $\hat{\mathbf{U}}$; nghĩa là, **chứa dữ liệu đã thu giảm còn M chiều**.

Dimensionality Reduction

Mục lục

Giới thiệu về PCA

PCA qua API

Kiến thức toán liên quan

Cơ sở lý luận của PCA

Cực đại hóa variance

47

Thu giảm số chiều

Singular Value Decomposition

Ứng dụng của PCA

Tổng kết và Câu hỏi

60

Thu giảm số chiều



Dimensionality Reduction

Mục lục

Giới thiệu về PCA

PCA qua API

Kiến thức toán liên quan

Cơ sở lý luận của PCA

Cực đại hóa variance

48 Thu giảm số chiều

Singular Value Decomposition

Ứng dụng của PCA

Tổng kết và Câu hỏi


- Thu giảm số chiều, xem Hình 6.1:

$$\hat{\mathbf{X}}_U = (\mathbf{X} - \mu^T) \hat{\mathbf{U}} = \mathbf{Z} \hat{\mathbf{U}} \quad (6.1)$$

- Phục hồi dữ liệu, xem Hình 6.2:


$$\begin{aligned} \hat{\mathbf{X}} &= \mu^T + \hat{\mathbf{Z}} \\ &= \mu^T + \hat{\mathbf{X}}_U \hat{\mathbf{U}}^{-1} \\ &= \mu^T + \hat{\mathbf{X}}_U \hat{\mathbf{U}}^T \end{aligned} \quad (6.2)$$

Thu giảm số chiều



Hình 6.1: Thu giảm số chiều

Thu giảm số chiều



Hình 6.2: Phục hồi từ dữ liệu bị thu giảm

Thu giảm số chiều



Dimensionality Reduction

Mục lục

Giới thiệu về PCA

PCA qua API

Kiến thức toán liên quan

Cơ sở lý luận của PCA

Cực đại hóa variance

51 Thu giảm số chiều

Singular Value Decomposition

Ứng dụng của PCA

Tổng kết và Câu hỏi

Giải thuật

- 1 Tính ma trận hiệp phương sai
- 2 Tính eigenvectors and eigenvalues (sử dụng `numpy.linalg.eig`; `numpy.linalg.eigh`)
- 3 Chọn M eigenvectors: $\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_M$ ¹
- 4 Chiếu dữ liệu gốc lên M vectơ để thu được dữ liệu mới

¹chọn M bằng kiểm thử chéo



Singular Value Decomposition

Dimensionality Reduction

Mục lục

Giới thiệu về PCA

PCA qua API

Kiến thức toán liên quan

Cơ sở lý luận của PCA

Cực đại hóa variance

Thu giảm số chiều

52

Singular Value Decomposition

Ứng dụng của PCA

Tổng kết và Câu hỏi

60

Singular Value Decomposition



Dimensionality Reduction

Mục lục

Giới thiệu về PCA

PCA qua API

Kiến thức toán liên quan

Cơ sở lý luận của PCA

Cực đại hóa variance

Thu giảm số chiều

53

Singular Value Decomposition

Ứng dụng của PCA

Tổng kết và Câu hỏi

60

❶ SVD là kỹ thuật tổng quát của PCA

❷ PCA:

❶ Tính ma trận hiệp phương sai

❷ Sử dụng **eigen-decomposition** trên ma trận hiệp phương sai


❸ SVD:

❶ Phân rã SVD trên chính ma trận gốc (**X**)

❷ Quá trình phân rã ổn định hơn (numerical stability)¹

¹Đọc thêm: <https://math.stackexchange.com/questions/3869/what-is-the-intuitive-relationship-between-svd-and-pca>

SVD



Hình 7.1: SVD: phân rã ma trận A thành $A = USV^T$

Dimensionality Reduction

Mục lục

Giới thiệu về PCA

PCA qua API

Kiến thức toán liên quan

Cơ sở lý luận của PCA

Cực đại hóa variance

Thu giảm số chiều

54

Singular Value Decomposition

Ứng dụng của PCA

Tổng kết và Câu hỏi

60

Singular Value Decomposition



Dimensionality Reduction

Mục lục

Giới thiệu về PCA

PCA qua API

Kiến thức toán liên quan

Cơ sở lý luận của PCA

Cực đại hóa variance

Thu giảm số chiều

55

Singular Value Decomposition

Ứng dụng của PCA


Tổng kết và Câu hỏi

60

① Ma trận dữ liệu gốc $\mathbf{X}$ được SVD phân rã thành $\mathbf{X} = \mathbf{U}\mathbf{S}\mathbf{V}^T$

- $\mathbf{U}$ là ma trận có kích thước $N \times N$; các cột của $\mathbf{U}$ là các eigenvector của ma trận $\mathbf{X}\mathbf{X}^T$
- $\mathbf{V}$ là ma trận có kích thước $D \times D$; các cột của $\mathbf{V}$ là các eigenvector của ma trận $\mathbf{X}^T\mathbf{X}$
- $\mathbf{S}$ là **ma trận đường chéo** có kích thước $N \times D$; giá trị trên đường chéo chính của $\mathbf{S}$ là các **singular value**, được sắp xếp từ lớn đến nhỏ.

SVD



Dimensionality Reduction

Mục lục

Giới thiệu về PCA

PCA qua API

Kiến thức toán liên quan

Cơ sở lý luận của PCA

Cực đại hóa variance

Thu giảm số chiều

56

Singular Value Decomposition

Ứng dụng của PCA

Tổng kết và Câu hỏi

60

Hình 7.2: SVD: xấp xỉ dữ liệu dựa vào các singular value

Singular Value Decomposition

Sử dụng SVD để thu giảm số chiều



Giải thuật

- 1 Tính $\mathbf{Z} = \mathbf{X} - \mathbf{m}^T$; với $\mathbf{m}$ là **total mean**,
$$\mathbf{m} = \frac{1}{N} \sum_{n=1}^N \mathbf{x}_n$$
- 2 Dùng SVD phân rã $\mathbf{Z} = \mathbf{USV}^T$ (sử dụng `numpy.linalg.svd`)
- 3 Chọn M vectơ đầu tiên của $\mathbf{V}$ (từ bên trái), tương ứng với M **singular value** lớn nhất để thành lập ma trận $\hat{\mathbf{V}}$.
- 4 Chiếu dữ liệu trong $\mathbf{Z}$ lên M eigenvector: $\mathbf{X}_{pca} = \mathbf{Z}\hat{\mathbf{V}}$

Dimensionality
Reduction

Mục lục

Giới thiệu về PCA

PCA qua API

Kiến thức toán
liên quan

Cơ sở lý luận của
PCA

Cực đại hóa
variance

Thu giảm số chiều

57

Singular Value
Decomposition

Ứng dụng của
PCA

Tổng kết và Câu
hỏi

60



Dimensionality Reduction

Mục lục

Giới thiệu về PCA

PCA qua API

Kiến thức toán liên quan

Cơ sở lý luận của PCA

Cực đại hóa variance

Thu giảm số chiều

Singular Value Decomposition

58 Ứng dụng của PCA

Tổng kết và Câu hỏi

60

Ứng dụng của PCA



Dimensionality Reduction

Mục lục

Giới thiệu về PCA

PCA qua API

Kiến thức toán liên quan

Cơ sở lý luận của PCA

Cực đại hóa variance

Thu giảm số chiều

Singular Value Decomposition

Ứng dụng của PCA

Tổng kết và Câu hỏi

Tổng kết



Dimensionality Reduction

Mục lục

Giới thiệu về PCA

PCA qua API

Kiến thức toán liên quan

Cơ sở lý luận của PCA

Cực đại hóa variance

Thu giảm số chiều

Singular Value Decomposition

Ứng dụng của PCA

PCA

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{U}^T$$
$$= \sum_{i=1}^r \lambda_i \mathbf{u}_i \mathbf{u}_i^T$$

- $\mathbf{A}$: ma trận hiệp phương
- r : hạng của ma trận $\mathbf{A}$
- thu giảm chiều $\equiv$ chỉ giữ lại M eigenvector và chiếu $\mathbf{X}$ lên các vectơ này

SVD

$$\mathbf{A} = \mathbf{U}\mathbf{S}\mathbf{V}^T$$
$$= \sum_{i=1}^r s_i \mathbf{u}_i \mathbf{v}_i^T$$

- $\mathbf{A}$: ma trận bất kỳ
- r : hạng của ma trận $\mathbf{A}$
- thu giảm chiều $\equiv$ chỉ giữ lại M eigenvector và xấp xỉ $\mathbf{X}$ lên các vectơ này